

SYNTHÈSE TECHNIQUE

Analyse des Fonctions Lambda AWS

Périmètre : Plateforme ACF — BPIFrance
Date d'analyse : 24/06/2026

Lambda	Rôle principal	Services AWS
acf-lambda-offset-forwarder	Déclenchement du job Glue avec calcul des offsets Kafka	S3, Glue Jobs, awswrangler
archive_ace-prod	Archivage et purge des données ACE obsolètes (6 mois)	S3, Glue Crawler
archive_anaplan-prd	Archivage mensuel des exports Anaplan avec partitionnement	S3, Glue Crawler

Les trois lambdas s'inscrivent dans un pipeline de données Data Lake (couche Silver) de la plateforme ACF de BPIFrance. Ils orchestrent respectivement l'ingestion des données Kafka, la purge du référentiel ACE et l'archivage des exports Anaplan.

Lambda 1 — acf-lambda-offset-forwarder-prd

Orchestrateur du pipeline Kafka → Glue Silver

Rôle et contexte

Cette Lambda est le point d'entrée du pipeline d'ingestion des données Kafka vers la couche Silver du Data Lake. Elle calcule les offsets Kafka à partir de la table `offset_manager` stockée en Parquet sur S3, puis déclenche le job Glue en lui transmettant les paramètres nécessaires.

Configuration

Paramètre	Valeur / Source	Description
ENVIRONMENT	Variable d'env (défaut : prod)	Détermine l'environnement cible (dev/staging/master-staging/prod)
GLUE_JOB_NAME	bpi-fr-{env}-acf-silver-mac-topic	Nom du job Glue à déclencher
OFFSET_MANAGER_PATH	s3://bpi-fr-{env}-acf-silver-data/mac/.../offset_manager/data/	Chemin S3 de la table Parquet offset_manager

Flux d'exécution détaillé

Mode 1 — Arguments fournis via l'événement (prioritaire)

- La Lambda reçoit un event contenant une clé **Arguments** (dict) ou des clés commençant par --.
- Ces arguments sont transmis directement au job Glue sans lecture S3.
- Cas d'usage : rejeu manuel d'un job avec des paramètres spécifiques.

Mode 2 — Calcul automatique depuis offset_manager (par défaut)

- Lecture du fichier Parquet depuis OFFSET_MANAGER_PATH via `awswrangler`.
- Validation des colonnes requises : **topic**, **partition**, **ending_offset**, **eventdate**.
- Calcul de la **date maximale** présente dans eventdate → **next_eventdate** = max + 1 jour.
- Groupement par **topic**, puis par **partition** → récupération de l'**offset maximum** par partition.
- Sérialisation du dictionnaire topic → {partition: offset} en JSON.

Déclenchement du job Glue

- Appel à `glue.start_job_run()` avec **JobName** et les arguments construits.
- Paramètres transmis : `--eventdate (YYYY-MM-DD)` et `--topics_offsets_json` (JSON stringifié).
- Retour du **JobRunId** dans la réponse HTTP 200.

Schéma de données traitées

Colonne offset_manager	Type	Rôle
topic	string	Nom du topic Kafka
partition	int	Numéro de partition Kafka
ending_offset	int	Dernier offset consommé par partition
eventdate	date	Date de l'événement — sert à calculer next_eventdate

Gestion des erreurs et retours

Cas	HTTP	Comportement
Succès (job lancé)	200	Retourne mode, job_name, job_run_id, arguments
Colonnes manquantes dans Parquet	500	Exception levée, message d'erreur retourné
DataFrame vide	500	ValueError : DataFrame vide
Environnement invalide	500	ValueError levée au démarrage (hors handler)
Erreur Glue	500	Exception capturée, message retourné

Points clés :

- La Lambda supporte deux modes d'exécution : pilotage externe (event) ou autonome (offset_manager). Le mode event est prioritaire.
- L'offset maximum par partition garantit qu'on ne rejoue jamais des données déjà consommées.
- $\text{next_eventdate} = \max(\text{eventdate}) + 1 \text{ jour}$: c'est la date que le job Glue utilisera pour partitionner les nouvelles données Silver.
- L'ENV_SHORT (prd/stg/dev/msp) est dérivé de ENVIRONMENT et intégré dynamiquement dans tous les noms de ressources AWS.

Lambda 2 — archive_ace-prod

Purge et archivage des données ACE — Rétention 6 mois

Rôle et contexte

Cette Lambda assure la **gouvernance de la rétention des données** pour les 17 tables ACE stockées dans la couche Silver du Data Lake. Elle lit une date de référence depuis un fichier CSV Anaplan, archive les fichiers correspondant à cette date dans un bucket de backup, puis supprime tous les fichiers dont l'*eventdate* est antérieure à 6 mois.

Buckets S3 impliqués

Bucket	Rôle	Préfixe clé
bpi-fr-{env}-acf-anaplan-data	Source de la date d'extraction de référence	Output/Export_Mensuel/ExporterDateExtractionSource.csv
bpi-fr-{env}-acf-silver-data	Données Silver ACE à archiver et purger	ACE/{TABLE}/eventdate={date}/*.parquet
bpi-fr-{env}-acf-data-backup	Destination des archives	Archives/ACE/{TABLE}/eventdate={date}/..

Tables ACE traitées (17 tables)

Tables	Tables	Tables
ADHESION_CLIENT_PROMOTION	COLLABORATEUR	CONTRAT_CLIENT_PROMOTION
CONTRAT_CLIENT	CONTRAT_PRESTATAIRE	DIAG_ACTION
ENTREPRISE_CLIENTE	FACTURE_PRESTATAIRE	ORDRE_PAIEMENT
PIECE_DE_VENTE	PRESTATAIRE	PRODUIT
PROJET_CONSEIL_INNOVATION	PROJET_INITIATIVE_CONSEIL	PROMOTION
UNIVERSITE	BESOIN_KYC	

Flux d'exécution détaillé

Étape 1 — Lecture de la date de référence

- Lecture du fichier **ExporterDateExtractionSource.csv** depuis le bucket Anaplan.
- Parsing : ligne 1 = header, ligne 2 = données. La date est nettoyée (suppression des accolades) et la première valeur CSV est extraite.
- Format attendu : YYYY-MM-DD. En cas d'erreur ou de format invalide → retour HTTP 500.

Étape 2 — Calcul de la date limite de purge

- Date limite = **date du jour - 6 mois** (via *relativedelta*).
- Tous les fichiers dont l'*eventdate* est strictement antérieure à cette date seront supprimés.

Étape 3 — Archivage des fichiers de la date de référence

- Pour chaque table parmi les 17, pagination S3 sur ACE/{TABLE}/ (1000 objets/page).

- Condition d'archivage : le chemin S3 contient eventdate={extraction_date}.
- Opération : s3.copy_object() vers bpi-fr-{env}-acf-data-backup avec préfixe Archives/ACE/.
- Les fichiers sont copiés mais PAS encore supprimés à cette étape.

Étape 4 — Purge des fichiers obsolètes

- Nouvelle pagination S3 sur ACE/{TABLE}/ pour chaque table.
- Extraction de l'eventdate depuis le chemin : parts[-2].replace('eventdate=', '').
- Condition de suppression : eventdate < six_months_ago_str.
- Opération : s3.delete_object() sur le bucket Silver. **dry_run = False** (suppression réelle).
- Les fichiers de la date de référence (archivés à l'étape 3) peuvent aussi être supprimés si leur eventdate < 6 mois.

Étape 5 — Déclenchement du Crawler Glue

- Appel à glue.start_crawler(Name='output_archive_ace') pour mettre à jour le catalogue.
- Erreur non bloquante : le crawler est lancé dans un try/except indépendant.

Gestion des erreurs

Cas	HTTP	Comportement
Fichier CSV absent ou malformé	500	Retour immédiat, aucune suppression
Date invalide dans le CSV	500	Retour immédiat
Erreur copie S3	—	Log erreur, traitement des autres fichiers continue
Erreur suppression S3	—	Log erreur, traitement continue
Aucun fichier pour une table	—	Log warning, table suivante traitée
Erreur Crawler Glue	—	Log erreur, retour 200 quand même
Succès complet	200	Message : Processus terminé avec succès

Points clés :

- Double passage S3 par table : 1er pour l'archivage, 2ème pour la purge. Optimisable en un seul passage.
- La purge est destructive (dry_run = False) : les fichiers sont supprimés définitivement du bucket Silver.
- La date d'extraction est lue depuis un fichier produit par Anaplan, créant une dépendance inter-systèmes.
- Les 17 tables sont traitées séquentiellement dans la même invocation Lambda — attention au timeout (max 15 min).
- Le crawler Glue 'output_archive_ace' est lancé à la fin pour synchroniser le catalogue de données.

Lambda 3 — archive_anaplan-prd

Archivage mensuel des exports Anaplan avec partitionnement eventdate

Rôle et contexte

Cette Lambda orchestre l'**archivage mensuel des exports CSV produits par Anaplan**. Elle vérifie la présence de tous les fichiers attendus, lit la période d'export depuis un fichier de contrôle, calcule le dernier jour du mois correspondant, puis archive les CSV dans une structure partitionnée par *eventdate* dans le bucket Silver — avant de supprimer les sources.

Configuration — Variables d'environnement

Variable	Défaut	Rôle
SOURCE_BUCKET	(obligatoire)	Bucket Anaplan source (bpi-fr-{env}-acf-anaplan-data)
TARGET_BUCKET	(obligatoire)	Bucket Silver cible (bpi-fr-{env}-acf-silver-data)
SOURCE_PREFIX	Output/Export_Mensuel/	Préfixe S3 des fichiers sources Anaplan
ARCHIVE_PREFIX	Output/output_archive_anaplan/Export_Mensuel/	Préfixe de destination dans le bucket Silver
PERIOD_FILE	ExporterPeriodeCalcul.csv	Fichier indiquant la période d'export (ex : Mar 26)
EXTRACTION_FILE	ExporterDateExtractionSource.csv	Fichier de date d'extraction (supprimé en fin de traitement)
EXPECTED_FILES	[] (JSON list)	Liste des chemins relatifs attendus — verrou de complétude

Flux d'exécution détaillé

Étape 1 — Validation de la complétude des fichiers

- Lecture de EXPECTED_FILES (liste JSON) : ensemble des fichiers requis pour que le traitement soit autorisé.
- Listage de tous les objets S3 sous SOURCE_PREFIX via pagination.
- Calcul des **fichiers manquants** = EXPECTED_FILES - existing_files.
- Si des fichiers manquent → retour HTTP 200 avec message 'Fichiers manquants', **aucun traitement**. Ce mécanisme évite un archivage partiel.

Étape 2 — Lecture de la période d'export

- Lecture de ExporterPeriodeCalcul.csv via csv.DictReader.
- Extraction du champ **PériodeExport** de la première ligne (ex : Mar 26 pour mars 2026).
- Si le fichier est absent → HTTP 200 (pas d'erreur, traitement silencieusement ignoré).
- Si le fichier est vide ou le champ absent → HTTP 200.

Étape 3 — Calcul du dernier jour du mois

- Parsing de la période : 3 premières lettres = mois abrégé, 2 derniers caractères = année (YY → 2000 + YY).
- Calcul du dernier jour via monthrange(year, month)[1] → eventdate = YYYY-MM-DD.
- Exemple : Mar 26 → 2026-03-31. Cette date devient la **partition Iceberg**.

Étape 4 — Archivage et suppression des CSV

- Pour chaque objet S3 source (hors fichiers de contrôle period et extraction) :
 - Vérification extension .csv uniquement.
 - Construction de la clé de destination : {ARCHIVE_PREFIX}{parent_dir}/eventdate={last_date}/{filename}
 - s3.copy_object() vers TARGET_BUCKET avec la clé structurée.
 - s3.delete_object() du fichier source dans SOURCE_BUCKET.
 - Comptage des fichiers traités.

Étape 5 — Maintien de la structure des dossiers

- Après archivage, les dossiers source seraient vides. Pour les maintenir visibles dans S3 :
- Création d'un **placeholder vide** (put_object Body=b") pour chaque dossier parent traité.

Étape 6 — Déclenchement du Crawler et nettoyage

- Si au moins 1 fichier traité → glue.start_crawler(Name='output_archive_anaplan').
- Suppression du fichier ExporterPeriodeCalcul.csv (consommé).
- Suppression du fichier ExporterDateExtractionSource.csv (ignoré si absent, pas d'erreur).

Structure de partitionnement générée

Avant archivage (Anaplan source) :

s3://bpi-fr-{env}-acf-anaplan-data/Output/Export_Mensuel/{DOSSIER}/{fichier}.csv

Après archivage (Silver Data) :

s3://bpi-fr-{env}-acf-silver-data/Output/output_archive_anaplan/Export_Mensuel/{DOSSIER}/eventdate=2026-03-31/{fichier}.csv

La partition eventdate={last_date_of_month} est compatible Iceberg/Athena/Trino — elle permet le data skipping sur la date.

Gestion des erreurs

Cas	HTTP	Comportement
Variable SOURCE_BUCKET ou TARGET_BUCKET absente	500	Exception levée, aucun traitement
EXPECTED_FILES JSON invalide	500	ValueError, aucun traitement
Fichiers attendus manquants	200	Arrêt silencieux, message 'Fichiers manquants'
ExporterPeriodeCalcul.csv absent	200	Arrêt silencieux, message explicite
PeriodeExport invalide (format)	500	ValueError avec message
Erreur copy/delete S3	500	Exception propagée (non catchée unitairement)
Succès complet	200	Message : '{N}' fichiers traités'

Points clés :

- Le mécanisme EXPECTED_FILES est un verrou de qualité : si l'export Anaplan est incomplet, aucun archivage n'a lieu.
- Le fichier ExporterPeriodeCalcul.csv joue le rôle de déclencheur : son absence = pas de traitement (logique idempotente).
- La partition eventdate=YYYY-MM-DD est toujours le dernier jour du mois, garantissant une cohérence temporelle mensuelle.
- Le placeholder vide évite la disparition des dossiers S3 (comportement AWS : les 'dossiers' n'existent que s'il y a des objets).
- Les fichiers de contrôle (period, extraction) sont supprimés en fin de traitement, signalant que le cycle est terminé.

Synthèse Comparative

Vue d'ensemble des 3 Lambdas

Comparatif fonctionnel

Critère	offset-forwarder	archive_ace	archive_anaplan
Déclenchement	Event ou schedulé	Schedulé (mensuel)	Schedulé (mensuel)
Lecture S3	Parquet (awswrangler)	CSV + scan complet	CSV + scan complet
Écriture S3	Aucune	Copy + Delete	Copy + Delete
Suppression données	Non	Oui (purge 6 mois)	Oui (source CSV)
Glue déclenché	Job Glue (Silver MAC)	Crawler ace	Crawler anaplan
Idempotence	Oui (offset max)	Non (double suppression possible)	Oui (period file)
Volume de données	Léger (metadata Parquet)	Potentiellement élevé (17 tables)	Modéré (exports CSV mensuels)
Risque timeout	Faible	Élevé (17 tables × pagination)	Modéré

Points de vigilance identifiés

Lambda ace-prod — Risque de timeout

- 17 tables × 2 passages S3 + paginations = potentiellement des milliers d'appels API selon le volume.
- Le timeout Lambda maximum est de 15 minutes. À surveiller en production si les tables sont volumineuses.

Lambda ace-prod — dry_run désactivé

- La variable dry_run est codée en dur à False : les suppressions sont réelles sans possibilité de simulation.
- Recommandation : externaliser ce paramètre en variable d'environnement ou en paramètre de l'event.

Lambda anaplan-prd — Erreurs copie/delete non catchées

- Contrairement à ace-prod, les erreurs S3 unitaires ne sont pas catchées : une seule erreur interrompt le traitement.
- Les fichiers déjà copiés mais non supprimés resteraient en source (cohérence à vérifier).

Lambda offset-forwarder — Initialisation hors handler

- Le mapping ENV_SHORT et la validation d'environnement sont exécutés à l'initialisation du module (hors lambda_handler).
- Un environnement invalide provoque une exception au cold start, ce qui est intentionnel mais peut masquer le diagnostic.

Vue d'ensemble du pipeline :

Kafka → [offset-forwarder] → Glue Job Silver MAC → S3 Silver (Parquet Iceberg, table mac_silver)

Anaplan → [archive_anaplan] → S3 Silver partitionné (eventdate=YYYY-MM-DD) → Crawler Glue → Catalogue

S3 Silver ACE → [archive_ace] → S3 Backup (Archives/ACE/) + Purge 6 mois → Crawler Glue → Catalogue

Les trois Lambdas sont déployées via Jenkins/EKS (pod Terraform agent Artifactory BPIFrance) avec le service account role-acf-cicd-prd.